

Wake W2d 단어 주소 런: 학습의 수식 표현

2026-09-14 · job 20260914-111212-d1542c · probes/wake_probe.py --arm encoder --words 120

0. 표기

기호	뜻
v_ϕ	frozen DiT (rectified-flow 속도장)
$\mathbf{E} \in \mathbb{R}^{N_{\text{ext}} \times 1024}$	vocab pack 의 ext row 테이블 (frozen). $\mathbf{E}_r = \text{row } r$
$\mathcal{R}$	이번 런이 다루는 ext row 집합 ($ \mathcal{R} = 246$)
$\mathcal{R}_{\text{tr}} \subset \mathcal{R}$	학습 캡션에 등장하는 row ($ \mathcal{R}_{\text{tr}} = 232$)
$\rho = \frac{1}{ \mathcal{R}_{\text{tr}} } \sum_{r \in \mathcal{R}_{\text{tr}}} \ \mathbf{E}_r\ \approx 195$	pack row 평균 노름. 모든 delta 는 이 단위
$x_r \in [0, 1]^{96 \times 96}$	row r 의 piece 텍스트를 15 개 폰트로 렌더한 잉크의 평균
$\psi_\theta : [0, 1]^{96 \times 96} \rightarrow \mathbb{R}^{1024}$	글리프 인코더 (CNN + MLP, 3.4M)
$\bar{\psi} = \frac{1}{ \mathcal{R} } \sum_{r' \in \mathcal{R}} \psi_\theta(x_{r'})$	테이블 전체의 평균 출력 (공통 모드)
$c \in \mathbb{R}^{1024}$	공유 레이아웃 벡터, $\ c\ \leq 0.75$
$f \in \mathbb{R}^{ \mathcal{R} \times 1024}$	row 별 자유 잔차
$s \in \{0, 1\}$	delta 스케일 (평가: 0 = floor, 1 = trained)

1. 텍스트 쪽: 주소

캡션 $c_{\text{txt}} = \text{"...Japanese text reads as "w"."}$ 에서 w 는 Qwen piece 열 $(p_1, \dots, p_k)$ 로 잘리고, 각 piece 는 pack 의 ext row r_i 로 라우팅된다. 단어 하나가 piece 하나면 (ありがとう, いい, って) row 도 하나다.

T5 쪽 쿼리 스트림이 보는 임베딩:

$$\tilde{\mathbf{E}}_r = \mathbf{E}_r + s \rho \Delta_r, \quad r \in \mathcal{R} \quad (1)$$

ext id 가 없는 프롬프트는 Δ 를 전혀 지나지 않으므로 EN 은 bit-exact 다.

2. delta 의 파라미터화 (hybrid)

$$\Delta_r = g_\theta(x_r) + \mathbf{1}[r \in \mathcal{R}_{\text{tr}}] f_r \quad (2)$$

$$g_\theta(x_r) = \alpha(\psi_\theta(x_r) - \bar{\psi}) + c, \quad \alpha = 2^{-4} \quad (3)$$

- $\psi_\theta(x_r) - \bar{\psi}$: 공통 모드를 테이블 전체에서 빼서, 공유 가중치가 모든 row 에 같은 방향으로 밀리는 그래디언트를 받지 않게 한다. 남는 것은 row 별 차이뿐이다.
- c : 빼낸 공통 모드 (" 빈 캔버스에 큰 글리프") 가 사는 자리. 매 step 후 $c \leftarrow c \cdot \min(1, 0.75/\|c\|)$ 로 투영.
- f_r : 학습 row 에만 붙는 잔차. Run 1d 에서 DiT 가 실제로 읽는 identity 는 g 가 아니라 여기 (노름 ≈ 0.9 , 서로 거의 직교) 에 실린다는 것이 확인됐다. 이번 런은 카나 row 134 개의 f 를 Run 1d 에서 warm start 하고, 단어 row 의 f 는 0 에서 시작한다.

3. 손실

이미지 y (폰트 렌더 또는 corpus 말풍선 크롭), $z_0 = \text{VAE}(y) \in \mathbb{R}^{16 \times 64 \times 64}$, $\varepsilon \sim \mathcal{N}(0, I)$, $\sigma \sim \mathcal{U}[0.7, 0.9]$:

$$z_\sigma = (1 - \sigma) z_0 + \sigma \varepsilon \quad (4)$$

$$\mathcal{L}_{\text{FM}} = \|v_\phi(z_\sigma, \sigma, T(c_{\text{txt}}; \mathbf{E} + \rho\Delta)) - (\varepsilon - z_0)\|_2^2 \quad (5)$$

$$\mathcal{L} = \mathcal{L}_{\text{FM}} + \mu \frac{1}{|\mathcal{R}_{\text{tr}}|} \sum_{r \in \mathcal{R}_{\text{tr}}} \|f_r\|^2, \quad \mu = 10^{-3} \quad (6)$$

$T(\cdot; \cdot)$ 는 캡션을 Qwen 소스 스트림 + delta 가 얹힌 T5 쿼리 스트림으로 인코딩하는 frozen 경로 (텍스트 인코더 + llm_adapter) 다. 그래디언트는 DiT 의 cross-attention 을 거슬러 임베딩 row 까지만 내려온다. σ 밴드 $[0.7, 0.9]$ 는 W2 에서 글리프 identity 가 $\sigma \approx 0.8$ 에서 결정된다는 결과에 맞춘 것이다.

μ 항은 g 가 설명할 수 있는 것은 g 로 밀어 넣고, f 에는 g 가 못 담은 row 별 크기만 남기려는 L2 pull 이다.

4. 최적화

AdamW (β_1, β_2) = (0.9, 0.99), weight decay 0, batch 4, 8000 step:

$$\theta : \eta = 3 \times 10^{-5} \text{ (cosine } \rightarrow 0), \quad c : \eta = 10^{-3}, \quad f : \eta = 10^{-3}.$$

5. 저장과 평가

학습 후 테이블을 한 번 굳힌다:

$$\Delta_r^* = g_\theta(x_r) + \mathbf{1}[r \in \mathcal{R}_{\text{tr}}] f_r, \quad r \in \mathcal{R}$$

그 뒤로는 ψ_θ 없이 Δ^* 만 ExtDelta 포맷으로 실는다 (eval / native / classify 가 그대로 돈다). 평가는 같은 seed 로 $s = 1$ 에서 샘플링하고 OCR 두 개 (sfx reader, PaddleOCR-VL) 로 읽어 CER 과 exact 를 센다.

6. 이 런이 묻는 것

단일 row 가 그려진다는 것은 Run 1d 에서 확인됐다 (trained 24/24). 이번 런은 $w = p_1 p_2$ (예: いや + いい) 일 때, 학습된 row 두 개 $\tilde{\mathbf{E}}_{r_1}, \tilde{\mathbf{E}}_{r_2}$ 가 나란히 들어간 시퀀스를 DiT 가 글리프 두 개로 그리는지를 묻는다. 지금까지의 combo / corpus 평가는 학습되지 않은 row 가 섞인 시퀀스였으므로 이 질문에 답한 적이 없다.

eval 그룹	내용	읽는 것
word	학습된 단어 16	단어 하나 = 주소 하나가 그려지는가
word_held	제외 단어 8	lookup 확인 (0 예상)
line	모든 piece 가 학습된 2-3 piece 대사 16	주소 나열이 그려지는가
single combo corpus en	이전 런과 같음	회귀 여부, EN 안전